

基于分层强化学习的多无人机动态目标围捕协同控制策略研究

第一章 绪论

1.1 研究背景与意义

1.1.1 多无人机协同避障的应用需求

- 多无人机协同避障广泛存在于巡检、搜救、编队运输与复杂环境侦察等任务中，强调群体层面的安全与效率。
- 任务环境通常具有障碍密集、信息不完整与动态扰动等特征，单机策略难以直接扩展到多机协同。
- 系统需要同时满足碰撞约束、队形/协作约束与实时响应约束，对规划与控制提出耦合挑战。
- 在工程实现上，策略不仅要“能飞”，还要具备稳定性、可控性与可解释的安全边界。

1.1.2 强化学习在无人机控制/规划中的优势与痛点

- 强化学习可直接从交互数据中学习复杂非线性策略，适合处理传统模型难以精确刻画的问题。
- 然而在连续控制与多智能体场景中，纯 RL 容易出现训练不稳定、样本效率低与策略震荡等问题。
- 受限于安全约束与物理可行性，探索空间被显著压缩，导致“学习速度—安全性”矛盾更加突出。
- 多机交互引入非平稳性与协作冲突，使得单一奖励与端到端策略更容易陷入局部最优或灾难性遗忘。

1.1.3 持续强化学习视角下的关键问题

- 多阶段训练（由易到难、由分离到融合）使策略面临跨分布迁移，持续学习要求策略在新场景适应的同时保持旧能力。
 - 灾难性遗忘在多任务与课程化训练中尤为突出，表现为后期性能提升伴随早期能力显著退化。
 - 持续强化学习需要在经验管理、训练调度与策略结构上进行系统设计，而不仅是更换网络或奖励。
 - 因此，本文从“分层解耦 + 任务分离 + 经验机制”的组合角度构建可持续优化的协同避障体系。
-

1.2 国内外研究现状

1.2.1 多无人机协同规划与避障方法

- 传统方法主要包括基于势场、基于图搜索/优化与基于规则的避障策略，优点是可解释但对复杂耦合约束适应性弱。
- 学习型方法通过数据驱动建模交互关系，具备在复杂场景中形成“隐式协作”的潜力，但稳定性与泛化仍是难点。
- 多无人机避障的核心难题在于“局部避障—全局协作”的冲突，尤其在密集场景容易产生拥堵与死锁。
- 现有工作在“可扩展性、实时性、安全约束”三者之间仍存在明显取舍。

1.2.2 分层强化学习在机器人/无人机中的应用进展

- 分层 RL 通过高层决策与低层控制分工，实现更清晰的策略结构与更强的可复用性。
- 在无人机任务中，常见做法是高层输出航迹/速度意图，低层负责跟踪与扰动抑制，从而降低学习难度。
- 但分层方法的关键在于层间接口设计与误差传播控制，否则可能出现“上层会规划、下层跟不上”的系统失配。
- 因此，稳定可执行的低层控制器与可学习的参数自适应能力是分层体系成立的基础。

1.2.3 元学习与课程学习在多任务与泛化中的研究进展

- 课程学习通过难度递进改善探索效率，适合从稀疏成功信号中逐步建立能力。
- 元学习通过跨任务训练获得“快速适应”的初始化或更新规则，为多场景泛化提供可行路径。
- 然而在多智能体协作中，任务分布变化不仅来自环境，还来自其它智能体策略变化，导致元训练更易不稳定。
- 因此，将元训练与任务分离相结合，用结构化目标降低相互干扰，是提升协同泛化能力的关键方向。

1.2.4 鲁棒控制与 LADRC 在飞行器控制中的研究进展

- LADRC 通过扩张状态观测器估计总扰动并进行补偿，具有较强的抗扰性与工程适用性。
- 其性能依赖观测器带宽与控制增益等参数，传统整定在多工况下难以同时兼顾响应速度与噪声敏感性。
- 在强扰动与模型不确定条件下，固定参数控制器容易出现过冲、振荡或响应迟滞，限制了上层策略的有效性。

- 因此，将 LADRC 参数引入可学习自适应机制，有望在保持鲁棒结构的同时提高跨工况性能。

1.2.5 经验回放与样本效率提升方法评述与不足

- 经验回放、N 步回报与优先采样等方法能提升样本利用率，但在多阶段训练中仍可能引入分布偏置。
 - 多智能体场景下经验的“时效性”更强，旧经验可能对应过时的对手策略，导致学习目标漂移。
 - 单一回放机制难以同时服务“稳定性、适应性、抗遗忘”，需要与任务结构与训练调度协同设计。
 - 因此，本文在规划层与控制层分别设计匹配其目标的经验与样本增强机制，并通过消融验证其必要性。
-

1.3 研究问题定义与挑战分析

1.3.1 协同避障中的“避障—合作”耦合冲突

- 避障目标强调远离危险区域，而合作目标强调维持队形/相对位置，两者在狭窄空间天然矛盾。
- 单策略同时优化两类目标时，奖励梯度可能相互抵消，导致策略既不够安全也不够协作。
- 当无人机数量增加或障碍密度升高时，该冲突会放大为拥堵、互相阻塞与局部死锁问题。
- 因此需要结构化拆分任务目标，并在融合阶段引入一致性机制而非简单加权叠加。

1.3.2 低层控制稳定性与上层探索之间的矛盾

- 上层策略需要探索多样动作以获得更优路径，但低层控制必须保证轨迹可跟踪且不引发姿态/速度发散。
- 若低层控制器在扰动下跟踪能力不足，上层学习到的“看似可行动作”会在执行时失效，造成学习信号污染。
- 纯 RL 低层控制在早期训练阶段易产生不稳定输出，降低整体系统安全性与训练效率。
- 因此，具有鲁棒结构的 LADRC 与可学习参数自适应结合，可在探索期提供稳定执行底座。

1.3.3 多智能体训练的非平稳性与样本效率瓶颈

- 多智能体策略在训练过程中同步变化，导致每个体感知到的环境呈现非平稳特性，价值估计更易偏移。

- 协作奖励通常稀疏或延迟，单纯依赖在线交互难以在有限步数内收敛到稳定协作模式。
- 经验复用在提升样本效率的同时可能引入分布偏差，需要与训练阶段和任务结构一致。
- 因此，本文将样本效率提升机制与分阶段训练调度绑定，降低非平稳带来的负面影响。

1.3.4 仿真到现实差距与鲁棒性需求

- 仿真环境与真实飞行在动力学、传感噪声、执行器迟滞等方面存在差异，策略可能出现迁移失效。
 - 障碍物感知误差与通信不可靠会放大协作策略的不确定性，要求控制与规划具备鲁棒性冗余。
 - 在真实系统中，安全约束优先级高于效率目标，策略必须具备可控的约束惩罚与失效保护机制。
 - 因此，本文在仿真中显式注入扰动与噪声，并以鲁棒控制结构作为低层保障以提高可迁移性。
-

1.4 本文研究内容与总体框架

1.4.1 分层框架总体思路：规划层—控制层解耦

- 本文采用规划层输出“意图动作”（如期望速度/加速度/航向），控制层输出可执行控制量并抑制扰动。
- 规划层关注多机交互与障碍分布，控制层关注跟踪精度、稳定性与执行器约束，两者职责清晰。
- 分层结构降低了上层学习难度，使协同策略可以在相对稳定的执行模型上迭代优化。
- 层间接口的统一定义保证方法可复现并支持后续扩展到更多任务。

1.4.2 控制层：RL-LADRC 自适应参数控制器 + 跨时间样本增强

- 控制层以 LADRC 为主体，利用 ESO 估计总扰动并进行补偿，保证在扰动与模型不确定下的鲁棒执行。
- 引入 RL 模块在线调节关键参数，使控制器能在不同工况与不同上层意图下保持响应与稳定性的平衡。
- 通过跨时间样本增强机制提升样本利用率与收敛速度，降低连续控制训练的不稳定性。
- 控制层的稳定输出为规划层提供可信执行反馈，形成“上层敢探索、下层能稳定”的协同闭环。

1.4.3 规划层：任务分离的元训练协同规划 + 多注意力/增长注意力结构

- 规划层将“避障”与“合作”拆分为两个子任务输出，减少奖励冲突并提高学习可解释性。
- 采用三编码器处理自身、障碍物与邻机信息，并通过双注意力结构分别建模风险交互与协作交互。
- 引入分阶段元训练/课程学习，先学习基本避障与协作能力，再在融合阶段形成稳定协同行为。
- 增长注意力模式使策略容量与关注范围随训练阶段逐步扩展，从而兼顾早期稳定与后期表达能力。

1.4.4 经验机制：分层金字塔经验池 + PER 优先回放策略

- 规划层构建按阶段/难度分桶的经验池结构，使不同训练阶段能够获得匹配的样本分布。
 - 使用优先回放提升关键样本（高风险、稀疏成功、关键转折）的学习占比，提高样本效率。
 - 经验机制与训练阶段联动，避免后期训练完全覆盖早期能力，从系统层面缓解遗忘问题。
 - 控制层与规划层的经验机制分工明确：控制层侧重稳定收敛，规划层侧重协作泛化。
-

1.5 本文创新点与贡献总结

- 提出规划—控制分层的多无人机协同避障框架，明确层间接口并形成可复现实验体系。
- 在控制层提出 RL-LADRC 参数自适应方法，并结合跨时间样本增强提高训练效率与稳定性。
- 在规划层提出“避障—合作”任务分离的分阶段元训练策略，配合双注意力与增长注意力网络结构。
- 设计分层金字塔经验池与 PER 优先回放机制，提升协同规划的样本利用率并缓解多阶段训练遗忘。

1.6 论文结构安排

- 第 2 章介绍四旋翼模型、PyBullet 任务定义及方法所需基础概念，为后续章节建立统一符号与接口。
- 第 3 章给出控制层 RL-LADRC 及跨时间样本增强机制，并通过对比与消融验证其稳定性与效率优势。
- 第 4 章给出规划层任务分离元训练方法、网络结构与经验机制，并在多场景泛化评估中验证协同效果。
- 第 5 章总结全文贡献，分析局限性并给出未来工作方向。

第二章 系统建模、仿真任务与算法基础（精简且“只铺垫”）

2.1 四旋翼无人机物理模型与约束

2.1.1 坐标系定义与状态量描述

- 明确世界坐标系与机体系的定义，并给出位置、速度、姿态、角速度等状态量符号。
- 说明状态向量在规划层与控制层的使用差异，例如规划层可用简化状态，控制层使用更高频状态。
- 给出观测可得性假设（全状态可观或部分可观），与后续观测设计保持一致。
- 统一符号与维度，为后续网络输入与奖励项的实现提供可复现基础。

2.1.2 运动学/动力学模型

- 给出四旋翼从控制输入到加速度/角加速度的基本关系，说明是否采用简化动力学或完整模型。
- 说明仿真中时间离散方式与更新频率，并与控制层控制周期/规划周期建立对应关系。
- 指出模型中忽略项（如空气阻力、耦合项）及其可能带来的偏差来源。
- 将模型复杂度与可学习策略的泛化需求联系起来，为引入鲁棒控制结构做铺垫。

2.1.3 控制输入形式与执行器约束

- 明确控制层输出的控制量形式（推力/姿态角/角速度/加速度），并说明为何选择该形式。
- 给出执行器饱和、速度限幅与角速度限幅的具体约束范围或归一化方式。
- 说明约束在训练中的处理方式（动作裁剪、惩罚项或安全过滤），并强调安全优先级。
- 强调约束会影响上层可执行空间，因此层间接口必须与约束一致。

2.1.4 扰动与不确定性建模口径

- 描述风扰、外力扰动与参数偏差的注入方式（随机常值、随机过程或分段变化）。

- 描述传感噪声与观测误差的模拟方式及强度设置，用于评估策略鲁棒性。
 - 指出扰动与不确定性是导致控制性能下降的主要来源，从而引出 LADRC 的必要性。
 - 明确扰动设置将在第 3/4 章实验中统一采用，保证可比性。
-

2.2 PyBullet 仿真环境与协同避障任务定义

2.2.1 仿真平台与实现概述

- 说明选用 PyBullet 的原因：物理真实性、可快速构建多体场景、便于批量采样训练。
- 给出仿真步长、动力学子步数与控制频率/规划频率等关键实现参数。
- 描述环境 reset、并行采样与随机种子控制方式，保证实验可复现。
- 说明仿真接口如何输出观测、接收动作以及记录指标。

2.2.2 场景构建：障碍物、边界与初始化

- 描述障碍物类型（静态/动态）、几何形状与分布生成策略（密度、最小间距等）。
- 定义飞行区域边界与越界判定规则，并说明边界惩罚或终止条件。
- 描述无人机初始位置、目标点、队形初始化方式与随机化范围。
- 强调场景随机化用于提升泛化能力，并与后续课程学习难度设置相兼容。

2.2.3 任务目标、约束与终止条件

- 明确核心目标：到达目标区域/完成航段，同时满足零碰撞与越界约束。
- 明确协作目标：保持队形、保持安全间距或完成合作运动（与你规划层“合作输出”一致）。
- 说明终止条件：成功到达、发生碰撞、越界、超时，以及对应日志记录方式。
- 将终止条件与奖励设计联系：哪些失败应给强惩罚，哪些属于可恢复偏差。

2.2.4 观测设计：自身—障碍物—邻机

- 给出自身观测的组成（位置/速度/朝向/目标相对量等）与归一化方式。
- 给出障碍物观测形式（最近 K 个障碍/栅格/射线），与第 4 章障碍编码器输入一致。
- 给出邻机观测形式（最近 M 个邻机的相对位姿/速度），与第 4 章邻机编码器输入一致。

- 说明观测的局部性假设（感知半径/通信半径），为协作难度与泛化评估提供边界。

2.2.5 动作设计：上层规划动作与下层控制指令

- 明确规划层动作输出形式（例如期望速度向量与合作修正量），以及两输出如何组合。
- 明确控制层接收的参考指令形式（期望速度/姿态/位置），并说明跟踪目标与误差定义。
- 说明动作裁剪与平滑处理的原则，以避免上层输出不可执行导致控制层饱和。
- 强调层间接口保持固定，使对比实验公平且方法可移植。

2.2.6 评价指标体系

- 定义安全类指标：碰撞率、最小安全距离分布、越界率。
 - 定义效率类指标：成功率、到达时间/路径长度、能耗近似指标。
 - 定义协作类指标：队形误差、相对距离保持误差、协作一致性。
 - 定义控制质量指标：速度/姿态抖动、控制量变化率，用于支撑第 3 章稳定性结论。
-

2.3 强化学习与多智能体训练基础

2.3.1 MDP/POMDP 建模与符号约定

- 给出状态、动作、奖励、转移与折扣因子定义，并说明是否部分可观测。
- 明确单机与多机的符号区别（个体索引、联合状态/联合动作）。
- 说明规划层与控制层分别对应的 MDP 建模对象与时间尺度。
- 将符号约定与后续伪代码变量名保持一致，减少阅读成本。

2.3.2 Actor-Critic 与 off-policy 训练要点

- 概述策略网络与价值网络的角色分工，以及连续动作空间下的常用实现方式。
- 说明为何选择 off-policy：支持经验回放、提高样本利用率、适合仿真并行采样。
- 说明目标网络、软更新与熵正则等稳定化组件是否使用及其目的。
- 强调本节只给“通用训练框架”，具体结构与机制在第 3/4 章展开。

2.3.3 多智能体非平稳性与 CTDE 口径（如使用）

- 指出多智能体训练中每个体面对的环境随其他体策略变化而改变，导致价值估计偏移。
- 若采用 CTDE，说明训练时可用全局信息以稳定学习，执行时只用局部观测以满足分布式部署。
- 说明你采用的交互方式（参数共享/独立策略）与其对可扩展性的影响。
- 将该非平稳性问题与第 4 章“任务分离 + 分阶段训练 + 经验管理”建立因果链。

2.3.4 常见训练稳定技巧（按实际使用）

- 说明观测与奖励归一化的必要性，以避免尺度不一致导致梯度不稳定。
 - 说明梯度裁剪、学习率调度等技巧对防止训练发散的作用。
 - 说明探索噪声或随机策略的设置原则，以平衡探索与安全约束。
 - 强调这些技巧为工程实现保障，并不构成本文主要贡献。
-

2.4 LADRC 基本原理与参数化空间

2.4.1 LADRC 结构：TD、ESO 与误差反馈律

- 概述跟踪微分器用于生成平滑参考或估计导数，减少高频噪声影响。
- 概述扩张状态观测器将未知扰动与未建模动态统一为总扰动并进行估计。
- 概述误差反馈律通过补偿扰动实现闭环稳定与快速响应。
- 强调 LADRC 结构天然适合在存在扰动与模型不确定条件下运行。

2.4.2 总扰动估计与鲁棒控制机理

- 指出总扰动估计将外扰、参数偏差与耦合项纳入观测器状态，提高抗扰能力。
- 说明扰动补偿使系统对模型精度依赖降低，为仿真到现实迁移提供鲁棒性基础。
- 讨论观测器带宽的双刃剑：带宽高响应快但噪声敏感，带宽低更稳但响应慢。
- 引出参数自适应需求：不同场景下最优带宽/增益不同，固定参数难以兼顾。

2.4.3 参数含义与调参难点

- 列出关键参数（观测器带宽、控制增益等）对跟踪速度、超调与稳定裕度的影响方向。
- 说明在多工况与多任务下人工调参成本高且难以系统化，影响方法可复现性。

- 说明参数约束必须与执行器约束一致，否则会导致控制饱和与振荡。
- 为第 3 章“RL 调参”的动作空间设计提供理论边界。

2.4.4 参数可学习化空间（为第 3 章铺垫）

- 明确哪些参数允许在线学习、哪些参数固定以保证结构稳定性。
 - 给出参数的可行范围与归一化方式，避免学习过程进入不稳定区域。
 - 说明参数更新频率与控制周期关系，避免高频抖动造成不必要的控制噪声。
 - 强调该可学习化仅定义“接口”，具体学习策略与增强机制在第 3 章给出。
-

2.5 分层强化学习与任务分离原理

2.5.1 分层 RL 基本思想与层间接口

- 定义规划层与控制层的职责边界：规划层做协同决策，控制层做稳定跟踪与扰动抑制。
- 给出层间信息流：规划层输出参考指令，控制层反馈执行结果与可选的低层状态摘要。
- 说明层间频率不同导致的采样问题，强调接口需要支持时间尺度差异。
- 强调分层减少学习维度，使规划策略可在稳定执行模型上迭代优化。

2.5.2 任务分离必要性：避免奖励冲突与策略干扰

- 指出避障与合作目标在局部空间常相互冲突，单头策略容易出现梯度干扰。
- 任务分离通过结构化输出让策略分别学习“安全反应”与“协作意图”，降低耦合难度。
- 分离输出为后续一致性约束提供清晰作用对象，避免简单加权导致的不可解释折中。
- 该结构也便于消融分析：可量化各子任务对总体性能的贡献。

2.5.3 元训练/课程学习定位（只作基础定位）

- 课程学习通过难度递增提高成功信号密度，减少早期训练的稀疏回报问题。
- 元训练强调跨场景快速适应，为不同障碍分布与不同队形初始化提供泛化能力。
- 说明本文采用分阶段训练调度：先学基础能力，再进行融合与协同精炼。
- 强调本节仅给概念与动机，具体阶段划分与切换规则在第 4 章给出。

2.6 常用训练稳定化与样本效率技术概述（只概述，不写你的创新细节）

2.6.1 经验回放（Replay Buffer）

- 经验回放通过复用历史交互样本降低样本相关性，提高学习稳定性。
- 对于 off-policy 算法，回放是提升数据效率的核心组件，适合仿真并行采样场景。
- 但回放会引入分布滞后问题，尤其在多智能体与多阶段训练中需要额外管理策略。
- 因此本文在后续章节结合任务结构设计更合适的经验组织方式。

2.6.2 优先经验回放（PER）

- PER 通过提高高 TD 误差样本的采样概率，加速关键状态的学习与价值传播。
- 在稀疏成功或高风险任务中，PER 能显著提高有效学习信号的利用率。
- 但优先采样可能放大分布偏置，需要与重要性采样或阶段性调度配合使用。
- 本文在第 4 章结合分阶段训练与经验池结构给出具体实现。

2.6.3 N 步回报（N-step Bootstrapping）

- N 步回报通过在短期真实回报与长期估计回报之间折中，加速奖励传播。
- 合理的 N 能在降低方差与降低偏差之间取得平衡，从而提升收敛速度。
- 在多智能体与高噪声环境中，N 的选择会显著影响稳定性，需结合实验确定。
- 本文在第 3 章将其作为样本增强组件之一并进行敏感性分析。

2.6.4 动作重复/动作保持（Action Repeat/Hold）

- 动作保持减少决策频率，有利于提升探索效率并降低控制抖动。
- 在物理系统中动作保持更符合执行器特性，有助于限制高频变化带来的不稳定。
- 但保持过长可能降低响应速度，需与控制层跟踪能力与任务难度共同考虑。
- 本文在第 3 章将其与跨时间样本增强组合使用并进行消融。

2.6.5 小结：从通用工具到结构化设计

- 本节给出通用样本效率与稳定化工具的概念框架，为后续方法设计提供背景。
 - 控制层与规划层面临的学习目标不同，因此同一工具需要不同的落地方式与调度策略。
 - 本文在第 3 章与第 4 章分别给出与其目标匹配的增强与经验机制。
 - 该分工保证第二章仅铺垫概念，核心贡献在方法章集中呈现。
-

2.7 本章小结

- 本章统一了四旋翼模型、仿真任务、观测动作与评价指标，为后续实验提供可复现底座。
 - 给出 RL、LADRC、分层与样本效率工具的基础概念与符号约定，避免后续章节重复定义。
 - 明确层间接口与任务结构的基本动机，为第 3 章控制层与第 4 章规划层方法自然铺垫。
 - 后续章节将在此基础上提出针对性的自适应控制与协同规划学习方法。
-

第三章 运动控制层：跨时间样本增强的 RL-LADRC 自适应参数控制器

3.1 控制层设计动机与总体框架

3.1.1 控制层职责与性能指标

- 控制层的核心目标是在扰动与约束条件下稳定跟踪规划层参考指令，并保持输出平滑可执行。
- 指标从跟踪误差（稳态/动态）、稳定性（振荡/超调）、鲁棒性（扰动恢复）与控制代价（能耗/变化率）四类建立。
- 强调控制层是上层探索的执行底座，控制失效会直接污染规划层学习信号。
- 因此控制层设计必须优先保证稳定性与可控的约束处理，再追求性能最优。

3.1.2 与规划层接口：输入输出与频率关系

- 明确控制层输入为规划层输出的参考（期望速度/姿态/位置等），并定义误差与误差变化率。

- 说明规划层频率较低、控制层频率较高的事实，并给出参考插值或保持策略。
- 说明控制层输出与执行器约束的映射方式，确保策略输出永远处于物理可行域。
- 强调接口固定后，后续对比实验可公平验证不同控制器的价值。

3.1.3 基线方法与对比协议

- 选择 PID、固定参数 LADRC 与纯 RL 控制作为基线，分别代表经典控制、鲁棒结构控制与端到端学习控制。
 - 对比协议保持相同仿真扰动、相同参考输入分布与相同评估指标，避免“换环境得结论”。
 - 指出纯 RL 控制早期不稳定的风险，并说明训练时的安全裁剪策略。
 - 该对比将支撑本文“结构+学习”优于纯结构或纯学习的结论。
-

3.2 RL-LADRC 参数自适应设计

3.2.1 LADRC 控制器结构在本系统中的落地

- 给出你采用的 LADRC 环路结构：控制对象、观测器、补偿项与误差反馈项之间的关系。
- 明确 ESO 估计的总扰动如何进入控制律，形成抗扰补偿闭环。
- 说明该结构与四旋翼模型/约束的适配点，尤其是对风扰与参数偏差的抑制作用。
- 将 LADRC 作为“稳定骨架”，为 RL 提供安全可控的调参空间。

3.2.2 状态空间设计（RL 输入）

- 状态至少包含跟踪误差、误差变化率、关键速度/姿态量以及扰动估计相关量（如 ESO 状态摘要）。
- 说明选择这些量的原因：既反映控制目标偏差，也反映系统当前可控性与扰动强度。
- 给出归一化与裁剪方式，避免尺度差异导致训练不稳定。
- 说明状态设计与奖励设计一一对应，确保学习信号可解释。

3.2.3 动作空间设计（可学习参数）

- 动作定义为对 LADRC 关键参数的调节量或目标值（如带宽、增益等），并给出其物理意义。
- 给出参数可行域与变化率限制，避免参数突变引发观测器发散或控制震荡。

- 说明动作输出频率与控制周期关系，必要时引入低通/保持机制抑制高频抖动。
- 强调动作空间设计的目标是“可学且安全”，而非把所有参数都交给 RL。

3.2.4 训练目标与优化方式（Actor-Critic 落地）

- 说明控制层使用 off-policy Actor-Critic 框架，以支持经验复用并提升样本效率。
- 价值网络拟合长期回报以稳定策略更新，策略网络输出参数调节动作。
- 说明关键训练超参数（折扣、软更新系数、探索噪声）及其对稳定性的作用口径。
- 强调后续跨时间样本增强将与该训练流程无缝结合。

3.2.5 约束处理与安全保护策略

- 说明执行器饱和与参数边界的处理方式（硬裁剪 + 软惩罚的组合更常见）。
- 引入控制量变化率约束或惩罚以减少抖振，保证可执行与能耗可控。
- 描述异常状态下的退化策略（例如回退到固定参数 LADRC），提升系统安全性。
- 强调这些保护机制使训练过程更稳定，并提高最终策略在扰动下的可靠性。

3.3 跨时间样本增强机制（控制层核心贡献）

3.3.1 设计动机：控制层为何需要跨时间增强

- 控制层奖励通常与误差收敛过程相关，单步更新学习信号弱且相关性强，导致收敛慢。
- 物理系统存在惯性与延迟，当前动作影响会跨多个时间步体现，需跨时间信息增强学习。
- 因此引入跨时间样本增强以加速回报传播并改善样本多样性。
- 本节的机制与控制层目标一致：优先提升稳定性与样本效率。

3.3.2 过去状态重播（Past State Replay）

- 定义重播的时间窗口与抽样规则，将历史关键状态再次加入训练，以强化对典型误差模式的学习。
- 强调重播不是简单重复采样，而是针对控制误差演化过程的“结构化回放”。

- 说明重播如何减少“只学到短期纠偏”的倾向，提升对长时间收敛过程的覆盖。
- 后续消融将验证其对收敛速度与稳态误差的贡献。

3.3.3 动作保持 (Action Hold)

- 定义动作保持时长与触发条件，使参数调节在短时间内保持一致，减少高频抖动。
- 动作保持提高了样本的有效探索跨度，使每次参数改变产生可观测的系统响应。
- 说明保持过短会退化为噪声探索，保持过长会降低响应，需通过实验选择合理范围。
- 后续敏感性实验将给出保持时长与性能之间的规律。

3.3.4 N步奖励自举 (N-step Bootstrapping)

- 给出N步回报的计算口径，将短期真实回报与远期价值估计结合以加速信用分配。
- 说明N对偏差与方差的影响，并提出选择原则（与控制系统时间常数同量级更合理）。
- 强调N步自举与过去状态重播互补：一个增强回报传播，一个增强典型过程覆盖。
- 在消融中比较不同N的训练稳定性与最终性能。

3.3.5 三者组合：跨时间样本增强的统一流程

- 说明组合流程如何嵌入标准 off-policy 训练：采样—增强—更新的闭环不改变主框架。
 - 给出组合策略的优先级：先保证动作保持稳定输出，再用N步传播与重播扩充有效样本。
 - 强调组合目标不是“堆技巧”，而是围绕控制层的稳定收敛规律进行结构化增强。
 - 指出该机制与后续规划层经验机制是“分层对应”的：控制层增强稳定，规划层增强协作与泛化。
-

3.4 控制层奖励函数设计（通用版本）

3.4.1 跟踪误差项

- 奖励核心由位置/速度（或姿态）跟踪误差构成，鼓励误差快速收敛且避免持续偏差。

- 可采用分量加权或范数形式，并在接近目标时提高精度权重以减少稳态误差。
- 说明误差定义与层间接口一致，避免“上层给速度、下层按位置算误差”的不一致。
- 误差项为控制层主要学习信号，其尺度需与其他惩罚项匹配。

3.4.2 控制能耗与平滑性项

- 引入控制输入幅值惩罚以降低能耗与饱和风险，提升可执行性。
- 引入控制输入变化率惩罚以抑制抖振，使输出更符合执行器与真实系统特性。
- 平滑项与动作保持机制共同作用：一个在目标层面惩罚抖动，一个在动作层面抑制高频变化。
- 说明平滑性指标也将作为实验评估指标之一，形成闭环验证。

3.4.3 约束与安全惩罚项

- 对越界、饱和与异常姿态/速度给出强惩罚或终止惩罚，确保安全优先。
- 明确哪些约束采用硬终止，哪些采用软惩罚，避免训练信号过于不连续。
- 将安全惩罚与扰动设置关联：在强扰动时更需要安全项约束策略输出。
- 说明该设计保证训练中不会通过“投机取巧”获得高回报。

3.4.4 权重设置与可迁移性说明

- 给出权重设置原则：先保证安全与稳定，再调节效率与能耗。
- 说明权重对性能的敏感性，并通过少量网格搜索或经验规则确定可复用范围。
- 强调奖励函数为通用版本，便于复现并为后续扩展任务提供直接可用模板。
- 在实验中通过消融与曲线展示证明该奖励不会导致策略对单一任务过拟合。

3.5 实验设计与评估指标

3.5.1 仿真设置与扰动设置

- 给出控制层实验场景：参考指令类型、轨迹形式、扰动注入方式与噪声强度。
- 说明训练与测试场景的差异（例如测试时更强扰动）以验证鲁棒性。
- 给出采样步数、并行环境数、随机种子数量与评估频率，保证统计可靠性。

- 强调所有对比方法共享相同设置，确保结论来源于方法差异。

3.5.2 对比组与实现一致性

- 对比 PID、固定 LADRC、纯 RL 控制与 RL-LADRC，确保控制目标与约束一致。
- 保持相同参考输入、相同动作限幅、相同观测噪声模型，避免隐含优势。
- 对学习方法的网络规模或报告参数量，以保证公平。
- 说明控制器初值与整定方式，保证基线性能合理而不被刻意压低。

3.5.3 指标体系（对应 3.1.1）

- 报告跟踪误差（均方/最大/稳态）、超调、收敛时间等，体现控制性能。
- 报告扰动恢复时间与误差峰值，体现鲁棒性。
- 报告控制量幅值与变化率统计，体现可执行性与平滑性。
- 报告训练效率指标（达到阈值性能所需步数），体现样本效率提升。

3.5.4 统计方式与可复现性

- 使用多随机种子报告均值与方差或置信区间，避免偶然性结论。
 - 固定评估协议（固定测试集场景）以进行纵向对比。
 - 记录关键超参数、网络结构与训练曲线，必要时在附录给出完整表格。
 - 强调可复现性是工程类论文可信度的重要组成部分。
-

3.6 结果分析与消融实验

3.6.1 综合性能对比

- 展示各控制器在不同扰动强度下的误差曲线与统计指标，证明 RL-LADRC 兼具稳定与性能。
- 分析 RL 调参带来的工况自适应能力，例如在强扰动时自动提高带宽/增益的趋势（若观察到）。
- 对比纯 RL 控制的早期不稳定与最终性能，强调结构化控制器对训练稳定性的贡献。
- 总结“鲁棒结构 + 学习调参”相较单独方法的优势来源。

3.6.2 消融：去掉过去状态重播

- 比较去掉重播后的收敛速度与稳态误差，验证其对典型误差过程学习的贡献。

- 分析没有重播时策略是否更易陷入只对近期误差做短视纠偏的模式。
- 给出在复杂参考或强扰动下的差异更明显的证据，提升论证力度。
- 说明重播增加的计算开销与收益的关系。

3.6.3 消融：去掉动作保持

- 比较去掉动作保持后的控制量变化率与振荡现象，验证其对抑制高频抖动的的作用。
- 分析动作保持对探索效率的影响：保持后单次动作影响更可观测，学习更稳定。
- 给出不同保持时长的敏感性趋势，说明合理区间。
- 总结动作保持在“学习稳定性—响应速度”之间的平衡角色。

3.6.4 消融：不同 N 步设置影响

- 报告不同 N 在收敛速度与最终性能上的差异，展示偏差—方差折中规律。
- 分析过小 N 导致回报传播慢，过大 N 导致估计不稳定或方差过大。
- 建议一个与系统响应时间相关的经验选取方法，提高方法可复用性。
- 说明最终选择的 N 与实验设置一致，并在后续实验中固定使用。

3.6.5 失败案例分析与原因归因

- 选取典型失败（强扰动下饱和、参数突变振荡、参考突变跟踪崩溃）进行轨迹与控制量可视化。
- 将失败归因到具体机制缺失或参数选择不当，而不是笼统归结为“训练不够”。
- 提出针对性改进方向（更强约束、分段保持、异常回退等），与第 5 章展望呼应。
- 通过失败案例增强论文可信度与工程可落地性。

3.7 本章小结

- 本章提出 RL-LADRC 参数自适应控制器，使鲁棒控制结构与学习能力互补。
 - 跨时间样本增强机制显著提升训练效率并改善控制输出平滑性与稳定性。
 - 实验对比与消融验证了各组件的必要性，并为第 4 章规划层提供稳定执行底座。
 - 控制层的稳定性保证上层协同规划训练更可靠，从而形成分层闭环优势。
-

第四章 规划策略层：任务分离的元训练协同规划方法

4.1 规划策略层问题建模与输出形式

4.1.1 规划层职责与目标

- 规划层负责在多机交互与障碍约束下生成可执行意图，使整体队伍安全到达目标并维持协作。
- 规划层目标同时包含安全性（避障/间距）、效率（路径/时间）与协作性（队形/一致性）。
- 规划层输出不直接作用于执行器，而是通过控制层跟踪，实现“决策—执行”分离。
- 因此规划层建模必须考虑控制层可执行域与跟踪误差，避免输出不可执行意图。

4.1.2 观测输入组织方式

- 将观测拆分为自身状态、障碍物集合与邻机集合三部分，分别具有不同的结构与尺度。
- 自身输入强调目标方向与自身速度姿态；障碍输入强调局部风险分布；邻机输入强调相对协作关系。
- 该组织方式与后续三编码器结构严格对齐，保证结构设计有明确对应关系。
- 说明局部观测半径/邻居数量截断策略，以保证复杂度可控且可扩展。

4.1.3 双输出器：避障运动输出 + 合作运动输出

- 避障输出用于生成安全运动分量，优先满足碰撞约束与安全距离约束。
- 合作输出用于生成协作分量，维持队形/一致性并减少互相阻塞。
- 双输出使任务分离可操作化：两类目标分别学习、分别评估、再在融合阶段协调。
- 输出组合方式在本节给出定义，融合一致性约束在 4.5 展开。

4.1.4 与控制层接口映射

- 定义规划层输出如何映射为控制层参考（例如速度向量→姿态/推力参考），确保可执行。
- 给出参考的限幅、平滑与保持策略，使控制层不会因突变参考而饱和或振荡。
- 说明控制层跟踪误差是否反馈给规划层（可选），以及反馈的形式（低维摘要）。

- 强调接口固定使规划策略训练与控制器可替换，增强方法模块化。
-

4.2 网络结构：三编码器 + 双注意力 + 增长注意力模式

4.2.1 三编码器结构设计动机

- 自身、障碍物、邻机三类输入结构不同：自身为向量，障碍/邻机为集合，需不同编码策略。
- 三编码器将异构信息映射到统一隐空间，便于后续注意力融合。
- 这种结构天然支持可扩展：障碍物/邻机数量变化只影响集合输入，不改变网络主体。
- 编码器输出将分别服务于两类注意力分支，形成“风险—协作”双通道信息流。

4.2.2 注意力一：自身—障碍物注意力（风险聚焦）

- 该注意力用于在障碍集合中聚焦最关键的风险源（近距离/高相对速度/路径阻塞）。
- 注意力权重提供可解释性：可展示策略“关注了哪些障碍”，支撑可视化分析。
- 风险注意力输出主要驱动避障输出器，使避障学习信号更集中、更稳定。
- 该结构减少对障碍排序与手工特征的依赖，提高泛化能力。

4.2.3 注意力二：自身—邻机注意力（协作聚焦）

- 该注意力用于聚焦对协作最关键的邻居（最近邻、队形关键点、潜在碰撞邻机）。
- 协作注意力输出主要驱动合作输出器，使策略能学习一致性与让行等隐式协作行为。
- 注意力机制缓解“邻机数量增加导致输入维度爆炸”的问题，提升可扩展性。
- 该分支与任务分离一致：协作信息主要影响合作输出而非直接污染避障学习。

4.2.4 增长注意力模式（Growth Mode）

- 增长注意力定义为：随课程阶段提升网络表达能力或扩大关注范围（如K/M增大或层数加深）。
- 早期阶段模型容量小、关注范围小，有助于稳定学习基本能力并减少过拟合与梯度噪声。

- 后期阶段逐步增长容量，使策略能表达更复杂的协作与拥挤场景下的精细决策。
 - 增长规则应与课程阶段切换一致，并在消融中验证其对泛化的贡献。
-

4.3 任务分离的分阶段元训练策略（课程学习）

4.3.1 阶段划分：先避障、再合作、再融合

- 第一阶段以避障为主，快速建立安全运动能力，保证基本生存能力与成功信号密度。
- 第二阶段引入合作目标，在安全基础上学习队形保持与协作规则，减少互相阻塞。
- 第三阶段融合训练，通过一致性约束协调两输出器，形成稳定的协同避障策略。
- 阶段划分与任务难度递增对应，使训练过程更可控、更可解释。

4.3.2 元训练目标：跨场景快速适应

- 训练任务分布包含不同障碍密度、不同目标布局与不同队形初始化，使策略学到可迁移结构。
- 元训练强调在少量更新或少量交互下适应新场景，从而提高泛化与持续学习能力。
- 说明元训练发生在阶段内部还是跨阶段（按你实际实现），并保持符号一致。
- 将元训练与增长注意力联系：策略在表达能力增长后更容易适应更复杂分布。

4.3.3 阶段切换规则（可复现口径）

- 使用可量化阈值触发切换，例如在固定测试集上成功率超过阈值且碰撞率低于阈值。
- 切换不仅依赖平均指标，还应限制方差或最差表现，避免偶然高分导致过早进入下一阶段。
- 说明切换后是否冻结部分网络、是否重置回放池或调整采样比例，与经验机制衔接。
- 该规则保证训练调度可复现，并使后续消融能定位问题来源于策略还是调度。

4.3.4 持续学习视角：避免遗忘的策略接口

- 在进入新阶段后保留旧阶段关键经验的访问通道，避免策略完全覆盖早期能力。

- 将经验管理与训练比例作为抗遗忘手段：新旧阶段样本按比例混采以保持能力。
 - 若使用正则或蒸馏等方法，可在此说明其接口（不一定必须有）。
 - 强调本文更偏向“结构化训练与经验管理”来缓解遗忘，与第 4.4 形成闭环。
-

4.4 经验机制：分层金字塔经验池 + PER 优先回放

4.4.1 金字塔经验池结构（分阶段/分难度/分任务）

- 经验池按阶段或难度分层存储，使不同训练阶段能采到“匹配难度”的样本。
- 可进一步按任务头分桶：避障经验池、合作经验池、融合经验池，减少梯度互相污染。
- 金字塔结构使稀缺但关键的困难样本不会被大量简单样本淹没，提高学习效率。
- 该结构与持续学习目标一致：保留旧阶段代表性样本以缓解遗忘。

4.4.2 PER 优先级定义（与协同任务一致）

- 优先级可由 TD 误差提供学习价值信号，并可叠加风险/碰撞近邻等任务相关权重以强调关键样本。
- 对避障头，提高“高风险但成功”的样本优先级可加速学习关键避障反应。
- 对合作头，提高“队形偏差大但可恢复”的样本优先级可强化协作纠偏能力。
- 优先级设计需要与重要性采样修正配合，避免采样偏置导致估计不稳定。

4.4.3 采样比例与更新节奏（阶段联动）

- 不同经验池设置采样比例，例如新阶段样本占比更高但保留一定旧阶段样本占比。
- 更新节奏与阶段切换联动：切换时可逐步改变采样比例而非瞬时切换，减少训练冲击。
- 可设置“困难样本保底采样”规则，确保策略持续接触关键难例。
- 该调度机制将直接影响抗遗忘与泛化能力，应在实验中给出敏感性说明。

4.4.4 与元训练/课程学习的耦合关系

- 课程阶段定义“学什么”，经验机制定义“用什么数据学”，二者必须一致才能稳定提升性能。
 - 元训练需要跨任务分布样本，因此经验池应覆盖任务多样性而非单一场景。
 - 在融合阶段，经验池应显式包含“冲突场景样本”（避障与合作冲突最强），以促进一致性学习。
 - 该耦合关系将作为第 4.7 消融与失败案例解释的重要依据。
-

4.5 规划层奖励函数设计：分任务奖励与融合一致性

4.5.1 避障奖励（安全优先）

- 避障奖励以安全距离、碰撞惩罚与越界惩罚为核心，确保策略不以效率换安全。
- 可加入“风险势能”或“最小距离”相关项，使策略提前规避而非临近急转。
- 对拥堵场景可加入通行效率项（如避免停滞），减少局部死锁。
- 避障奖励主要驱动避障输出器，确保任务分离结构的学习信号清晰。

4.5.2 合作奖励（协作可度量）

- 合作奖励以队形误差、相对距离保持误差与速度一致性为核心，促进稳定编队运动。
- 可加入“让行/分离”相关项以减少互相阻塞，使合作不等同于死守队形。
- 奖励应避免过强约束导致策略在避障时不敢破坏队形，从而与避障目标冲突。
- 合作奖励主要驱动合作输出器，为融合一致性提供基础。

4.5.3 融合一致性项（避免两输出“打架”）

- 一致性项用于约束避障输出与合作输出在方向/幅度上的冲突，避免合成动作震荡。
- 可以采用冲突惩罚（如两向量夹角惩罚）或门控融合（如在高风险时降低合作权重）。
- 一致性机制使融合阶段训练可控，避免简单加权叠加导致不可解释折中。
- 该项是任务分离结构闭环的关键，必须配合消融展示其必要性。

4.5.4 权重设置与奖励可迁移性

- 权重设置遵循安全优先：碰撞/越界惩罚最大，其次是队形与效率。

- 给出权重选择过程与范围，使方法可复现且便于后续扩展任务。
 - 说明奖励在不同障碍密度/不同无人机数量下是否需要重新调整，并给出你的处理策略。
 - 强调结构化奖励与结构化网络匹配，减少“靠调权重堆出来”的不稳健性。
-

4.6 仿真实验与结果分析

4.6.1 场景设置与难度维度

- 定义多组场景：不同障碍密度、不同障碍分布、不同目标布局与不同队形初始化。
- 定义规模维度：无人机数量从小到大递增，测试可扩展性与拥堵行为。
- 定义扰动维度：风扰与噪声强度变化，测试鲁棒性与稳定性。
- 场景维度与课程阶段对应，保证训练调度与评估一致。

4.6.2 对比方法与公平设置

- 对比无任务分离（单头输出）、无增长注意力、无元训练/无课程、无PER/无金字塔池等。
- 保持相同控制层、相同层间接口与相同训练预算，避免跨模块差异影响结论。
- 对比中尽量只替换一个因素，保证结论可归因。
- 明确对比方法的网络规模与参数量，以防“更大模型赢了”的争议。

4.6.3 指标与曲线呈现方式

- 报告成功率、碰撞率、最小安全距离分布等安全指标，作为首要评价。
- 报告平均到达时间/路径长度与能耗近似，评价效率。
- 报告队形误差与协作一致性，评价合作质量。
- 给出训练曲线与泛化曲线，展示“学得快”与“泛化强”两类证据。

4.6.4 泛化评估与持续学习表现

- 在未见过的地图分布、未见过的障碍密度或未见过的队形初始化上测试泛化。
- 将阶段 1/2 能力在融合阶段后的保持程度量化，体现抗遗忘效果。
- 对规模扩展场景给出性能衰减趋势，体现方法可扩展边界。
- 泛化结果与经验机制、增长注意力、任务分离的设计动机形成闭环论证。

4.6.5 典型轨迹可视化与机制解释

- 展示典型成功轨迹：如何绕障、如何让行、如何恢复队形，以直观体现协作。
 - 展示典型失败轨迹：拥堵、相互阻塞、局部死锁，并与注意力权重或输出冲突对应解释。
 - 用注意力可视化展示策略关注对象变化，增强可解释性与说服力。
 - 将可视化与定量指标一致对齐，避免“看起来好但指标不支持”的问题。
-

4.7 消融实验与失败案例分析

4.7.1 消融：去掉增长注意力

- 比较无增长注意力时的训练稳定性与后期复杂场景性能，验证“逐步扩容”的价值。
- 分析无增长时是否出现过拟合早期简单场景或后期学习受限的现象。
- 展示注意力范围/邻居数量变化对拥堵场景性能的影响规律。
- 总结增长注意力在“早期稳定—后期表达”之间的平衡作用。

4.7.2 消融：去掉任务分离（单头策略）

- 比较单头策略与双输出策略在碰撞率与队形误差上的差异，验证任务分离缓解冲突的必要性。
- 分析单头策略是否更易出现拥堵或死锁，尤其在高密度障碍与多机规模下。
- 展示奖励冲突的证据：训练中指标此消彼长或策略在两目标间摇摆。
- 总结任务分离提供了更清晰的学习信号与更稳定的协作行为。

4.7.3 消融：去掉金字塔经验池

- 比较去掉经验分层后的学习效率与泛化性能，验证“难例不被淹没”的必要性。
- 分析无分层时是否出现对新阶段过拟合导致旧阶段能力退化（遗忘加重）。
- 给出经验分布统计或样本难度分布可视化，支撑机制解释。
- 总结经验结构是持续学习系统性设计的重要组成部分。

4.7.4 消融：PER 替换为均匀回放

- 比较 PER 与均匀回放在稀疏成功与高风险样本学习上的差异，验证优先策略的价值。
- 分析均匀回放是否导致学习信号被大量平庸样本稀释，收敛更慢。

- 若存在偏置风险，展示重要性采样或优先级退火策略的作用（按你实现写）。
- 总结 PER 为协同规划提供更高样本效率，但需要与经验池结构联动。

4.7.5 失败案例归因：协作失效/拥堵/局部最优

- 选取典型失败：狭窄通道拥堵、互相让行失败、合作输出与避障输出冲突震荡。
 - 将失败归因到具体组件缺失（无一致性约束、无协作注意力、经验分布不足等）。
 - 给出可解释证据：注意力权重异常、输出冲突角度增大、关键样本未被采样等。
 - 将改进方向与第 5 章展望对齐（动态障碍、通信不可靠、更多约束形式）。
-

4.8 本章小结

- 本章提出任务分离的协同规划方法，并通过双注意力结构显式建模风险交互与协作交互。
 - 分阶段元训练与增长注意力模式使策略从基础能力到复杂协作逐步提升，训练更稳定可控。
 - 分层金字塔经验池与 PER 提高样本利用率并缓解遗忘，显著提升泛化与规模扩展性能。
 - 与第 3 章控制层共同构成“决策可学、执行可控”的分层闭环系统。
-

第五章 总结与展望

5.1 全文总结

5.1.1 总体框架回顾

- 本文构建规划—控制分层体系，将协同决策与稳定执行解耦，提高学习可控性。
- 层间接口统一定义，使控制器与规划器可替换并支持模块化扩展。
- 系统以持续学习目标组织训练调度与经验管理，强调跨阶段能力保持。
- 该框架在多场景、多扰动与多规模设置下实现稳定协同避障。

5.1.2 控制层贡献总结

- 提出 RL-LADRC 自适应参数控制器，在鲁棒结构基础上实现跨工况性能自适应。
- 跨时间样本增强显著提升样本效率与训练稳定性，并改善控制输出平滑性。
- 对比与消融证明“结构 + 学习 + 增强”的组合优于单一方法。
- 控制层稳定性为规划层训练提供可靠执行底座，形成系统性优势。

5.1.3 规划层贡献总结

- 提出“避障—合作”任务分离的元训练协同规划，缓解奖励冲突并提高可解释性。
- 双注意力与增长注意力实现从风险聚焦到协作聚焦的结构化信息融合。
- 金字塔经验池与 PER 提升关键样本利用率并缓解多阶段训练遗忘。
- 多场景泛化与规模扩展实验验证了方法的协作能力与鲁棒性。

5.1.4 综合实验结论与关键发现

- 规划层性能提升依赖于控制层稳定执行，分层结构有效降低非平稳与执行失配。
 - 任务分离与一致性机制是解决协作冲突与拥堵死锁的重要因素。
 - 经验结构与阶段调度对持续学习表现至关重要，单纯加大训练步数无法替代系统设计。
 - 失败案例分析揭示了方法边界，并为后续改进提供方向。
-

5.2 局限性分析

5.2.1 仿真与真实差距

- 仿真动力学与真实系统存在差异，尤其是执行器迟滞、传感误差与环境扰动复杂性。
- 纯仿真训练可能对特定噪声模型过拟合，导致真实迁移性能不确定。
- 需要更系统的域随机化与真实数据校准来缩小差距。
- 因此本文结论主要在仿真层面成立，真实部署需进一步验证。

5.2.2 观测/通信假设边界

- 本文采用的局部观测与邻机信息获取方式依赖感知或通信假设，实际系统可能不稳定。
- 通信延迟与丢包会影响协作注意力输入，从而降低协作可靠性。
- 需要引入鲁棒的缺失信息建模与不确定性估计机制。
- 该问题尤其在规模扩展与动态障碍场景中更突出。

5.2.3 规模扩展与复杂度

- 随无人机数量上升，交互关系数量增长，注意力计算与经验管理复杂度增加。
 - 尽管注意力机制缓解了输入维度爆炸，但仍需要更高效的邻居选择与稀疏化策略。
 - 训练成本与推理实时性需要在工程部署中进一步评估。
 - 因此本文提供了可扩展方向，但并未彻底解决超大规模协作的所有问题。
-

5.3 未来工作展望

5.3.1 更真实动力学与域随机化/参数辨识

- 引入更真实的动力学模型与执行器特性，并通过域随机化覆盖更广扰动分布。
- 利用参数辨识或在线估计减少模型不确定性，使控制层自适应更具工程一致性。
- 将真实飞行日志用于校准噪声与扰动模型，提高仿真可信度。
- 推动从仿真验证走向半实物或实机验证。

5.3.2 三维复杂场景与更丰富障碍建模

- 扩展到三维复杂地形与动态障碍，提升任务贴近真实应用。
- 引入障碍物尺寸、速度与不确定性等多维信息，使规划更鲁棒。
- 将“增长注意力 + 分阶段训练”推广到更复杂的场景递进设计。
- 形成更通用的协同避障任务基准与评估体系。

5.3.3 更复杂协作任务与安全强化学习

- 引入编队重构、多目标点、任务分工等更高层协作目标，验证方法可扩展性。
 - 研究安全强化学习或形式化约束方法，将安全约束从惩罚项提升为硬约束保证。
 - 将经验机制扩展为可解释的风险记忆与失败案例库，提升持续学习效率。
 - 进一步提升策略在极端场景下的可靠性与可解释性。
-

二、第3章 / 第4章“算法描述模板”（含伪代码小节标题 + 骨架）

下面给你的是写作模板：你按这个结构填入符号、网络、超参即可，审稿人最吃这一套，因为清晰、可复现、可消融。

第三章 算法描述模板（控制层 RL-LADRC + 跨时间样本增强）

建议小节结构（你可以直接替换你现有 3.2/3.3 的一部分标题）

- 3.2.6 问题形式化与目标函数（把“控制层 MDP”说清楚）
- 3.2.7 策略参数化与约束映射（动作如何变成 LADRC 参数）
- 3.3.6 跨时间样本增强的统一训练流程（把增强机制写成算法）
- 3.3.7 复杂度与实现细节（一页以内，写清楚可复现点）

伪代码小节标题（推荐）

- 算法 3-1: RL-LADRC 参数自适应控制器训练流程
- 算法 3-2: 跨时间样本增强 (PSR + Action Hold + N-step) 回放与更新流程

伪代码骨架（可直接放论文，变量名按你符号替换）

算法 3-1: RL-LADRC 参数自适应控制器训练流程

输入：控制环境 Env_c ，初始 LADRC 参数 θ_0 ，策略网络 π_ϕ ，价值网络 Q_ψ ，

回放池 B ，动作保持步数 H ， N 步长度 N ，训练步数 T

输出：训练后的策略参数 ϕ^*

- 1: 初始化 ϕ, ψ ；设置当前 LADRC 参数 $\theta \leftarrow \theta_0$ ；清空回放池 B
- 2: for $t = 1 \dots T$ do
- 3: 观测控制状态 s_t （误差、误差变化、ESO 摘要等）
- 4: 若到达保持切换时刻: $a_t \leftarrow \pi_\phi(s_t) + \text{exploration_noise}$
- 5: 将动作 a_t 映射为 LADRC 参数更新: $\theta \leftarrow \text{clip}(g(\theta, a_t))$
- 6: 用 $\text{LADRC}(\theta)$ 执行一步控制，得到 r_t, s_{t+1} , done

```

7:   将转移  $(s_t, a_t, r_t, s_{t+1}, done)$  暂存到轨迹缓存  $\tau$ 
8:   若  $\tau$  满足 N-step 计算条件或 done:
9:       计算 N 步回报  $R_t^{\{N\}}$ , 构造增强样本  $e_t$ 
10:      将  $e_t$  写入回放池 B (可叠加过去状态重播规则)
11:   从 B 采样小批量, 更新  $Q\psi$  与  $\pi\phi$  (off-policy Actor-Critic)
12:   若 done: 重置环境与轨迹缓存  $\tau$ 
13: end for
14: 返回  $\phi^*$ 

```

算法 3-2: 跨时间样本增强回放与更新流程 (PSR + Hold + N-step)

输入: 轨迹缓存 τ , 回放池 B, 过去状态重播窗口 W, 动作保持步数 H, N 步长度 N

输出: 写入 B 的增强样本集合 E

```

1:  $E \leftarrow \emptyset$ 
2: 对  $\tau$  中每个时间步 i:
3:     构造动作保持标记  $h_i$  (表示该动作在后续 H 步保持)
4:     构造 N 步回报  $R_i^{\{N\}} = \sum_{k=0}^{N-1} \gamma^k r_{i+k} + \gamma^N V(s_{i+N})$ 
5:     形成增强样本  $e_i = (s_i, a_i, R_i^{\{N\}}, s_{i+N}, done)$ 
6:      $E \leftarrow E \cup \{e_i\}$ 
7: 从  $\tau$  中按规则选择过去状态集合  $S_{psr}$  (窗口 W 内的关键状态或高误差状态)
8: 将 ( $S_{psr}$  对应的样本) 以重播权重写入 B
9: 将 E 写入 B (可设置写入比例或优先级)
10: 返回

```

写作要点:

- $g(\theta, a)$ 表示“动作到参数”的映射; clip() 表示安全边界。
- PSR (过去状态重播) 在算法里体现为第 7 - 9 步的“选择 + 加权写入”。
- 你后面消融就直接说: 把算法 3-2 中的某一段关掉即可。

第四章 算法描述模板 (规划层: 任务分离 + 元训练/课程 + 增长注意力 + 金字塔经验池 + PER)

建议小节结构 (更像期刊/学位论文“方法章”)

- 4.2.5 信息流与输出合成规则 (两输出如何合成, 何时门控)
- 4.3.5 训练日程 (Schedule) 与阶段切换规则 (表格化, 最加分)

- 4.4.5 经验池结构与 PER 优先级公式（把你的“金字塔+PER”写成算法）
- 4.5.5 一致性约束的形式化与稳定性讨论（为什么不打架）

伪代码小节标题（推荐）

- 算法 4-1：任务分离的分阶段元训练协同规划总体流程
- 算法 4-2：增长注意力（Growth Mode）阶段扩展规则
- 算法 4-3：分层金字塔经验池 + PER 的采样与更新流程

伪代码骨架（可直接放论文）

算法 4-1：任务分离的分阶段元训练协同规划总体流程

输入：规划环境 Env_p ，阶段集合 $K=\{1:\text{避障}, 2:\text{合作}, 3:\text{融合}\}$ ，
策略网络 π_Φ （含避障头 π_a 与合作头 π_c ），价值网络 Q_Ψ ，
经验池集合 $\{B_k\}$ ，阶段切换阈值 Θ ，训练轮数 T
输出：训练后的规划策略 Φ^*

```

1: 初始化  $\Phi, \Psi$ ；初始化各阶段经验池  $B_1, B_2, B_3$ 
2: for stage  $k$  in  $K$  do
3:     设置阶段目标与奖励:  $r \leftarrow r_k$ （避障/合作/融合一致性）
4:     while 未满足阶段切换条件  $\Theta$  do
5:         重置环境，采样一个任务实例  $m$ （不同障碍/队形/目标）
6:         for episode = 1 ...  $E$  do
7:             for  $t = 1 \dots T_{ep}$  do
8:                 观测  $s_t$ （自身/障碍/邻机）
9:                 计算避障动作  $u_t^a = \pi_a(s_t)$ ，合作动作  $u_t^c = \pi_c(s_t)$ 
10:                合成最终意图  $u_t = \text{Fuse}(u_t^a, u_t^c, \text{stage}=k)$ 
11:                执行一步得到  $r_t, s_{\{t+1\}}, done$ 
12:                将转移写入对应经验池  $B_k$ （并更新优先级信息）
13:                从  $\{B_k\}$  采样小批量，更新  $Q_\Psi$  与  $\pi_\Phi$ 
14:                若  $done$ : break
15:            end for
16:        end for
17:    end while
18: end for
19: 返回  $\Phi^*$ 

```

算法 4-2：增长注意力（Growth Mode）阶段扩展规则

输入：当前阶段 k ，注意力配置 C_k （邻居数量/障碍数量/层数/隐维等），性能指标 M

输出：更新后的注意力配置 $C_{\{k+1\}}$

```

1: if k 从 1 切换到 2 或 k 从 2 切换到 3 then
2:     根据配置规则增加关注范围（如  $K_{obs} \uparrow$ ,  $M_{nbr} \uparrow$ ）或增加表达能力（如  $hidden\_dim \uparrow$ ）
3:     可选：对新增参数随机初始化，对旧参数保持，避免破坏已学能力
4:     可选：短暂冻结部分层或降低学习率，平滑过渡
5: end if
6: 返回  $C_{\{k+1\}}$ 

```

算法 4-3：分层金字塔经验池 + PER 的采样与更新流程

输入：经验池集合 $\{B_k^d\}$ （阶段 k 、难度 d ），优先级 $p(e)$ ，采样比例 ρ_k^d ，

批量大小 n ，重要性采样系数 β

输出：用于更新的批量样本 $batch$

```

1:  $batch \leftarrow \emptyset$ 
2: for each  $(k, d)$  do
3:     从  $B_k^d$  按比例采样  $n_k^d = \text{round}(\rho_k^d * n)$ 
4:     在  $B_k^d$  内按 PER 概率  $P(e) = p(e)^\alpha / \sum p(\cdot)^\alpha$  采样样本
5:     计算重要性权重  $w(e) = (1 / (|B| * P(e)))^\beta$ ，并归一化
6:      $batch \leftarrow batch \cup \{(e, w(e))\}$ 
7: end for
8: 用  $batch$  更新  $Q\psi$  与  $\pi\phi$ 
9: 用新的 TD 误差/风险信号更新优先级  $p(e)$ 
10: 返回  $batch$ 

```

写作要点：

- $Fuse()$ 是你任务分离闭环的关键：避障/合作如何合成、何时门控，建议你在 4.2.5 用一张示意图说明。
- $\{B_k^d\}$ 是“金字塔经验池”的论文级表达：阶段 $k \times$ 难度 d 的二维结构，天然对应课程学习与持续学习。
- PER 的优先级 $p(e)$ 你可以写成：TD 误差 + 风险项（最小距离/碰撞近邻/拥堵状态），但要在实验里做消融。

三、最后给你一个“写作把控的硬规则”（保证结构最佳）

- 第二章只回答：我们在什么世界里？定义了什么任务？用什么符号？基本工具是什么？
- 第三章回答：控制层怎么做、为什么稳、怎么训练、增强机制怎么提升效率。

- 第四章回答：规划层怎么协作、为什么不冲突、怎么课程化训练、经验怎么管理以抗遗忘与提泛化。
 - 每个机制都必须对应一个消融点（你已经具备：PSR / Hold / N-step；增长注意力；任务分离；金字塔池；PER；一致性约束）。
-

如果你希望我把它做到“直接上论文排版”的程度：我可以再帮你把 **第 3 章 / 第 4 章每个算法的“符号表 + 变量解释 + 复杂度分析句式模板 + 消融对应表” **一起补全（这样你写实验部分会非常顺）。